

Выбор академической модели

Семб: вход $3 \times S \times S$, семб В, FP 32, eval() + inference_mode()

1. Консолидация

- 1) FLOPs: 1 MAC = 2 FLOPs. (считаем только Conv и Linear. ReLU, выделение и изменение bias не учитываем ($\approx 0.2\%$ вычисл.)
 - 2) Bytes moved: суммируем сущности, касающиеся сем. Каждому kernel считаем вход и берем из DRAM и пишем back. FP 32 = 4 байта, kernel MaxPool (int 64) = 8 байт
 - 3) Memory: нем torch.cuda.max_memory_allocated() за один forward под inference_mode
 - 4) Latency: средняя времени одного forward & eval() + inference_mode(), FP 32
 - 5) Energy: жернул всего GPU за один forward, в Дж.
- Семб: BatchNorm нем, у Conv bias=False, у Linear bias есть, все ReLU inplace.

2. Размеры нейронов

$$H_{out} = \left\lfloor \frac{H + 2P - k}{s} \right\rfloor + 1, P = \lfloor k/2 \rfloor \Rightarrow H_{att} = H (s=1), H_{att} = H/2 (s=2)$$

Выходы на изображение:

$$\text{conv 1: } 32 \left(\frac{S}{2} \right)^2 = 8S^2$$

$$\text{MaxPool: } 32 \left(\frac{S}{4} \right)^2 = 2S^2$$

$$\text{conv 2: } 64 \left(\frac{S}{4} \right)^2 = 4S^2$$

$$\text{conv 3: } 128 \left(\frac{S}{8} \right)^2 = 2S^2$$

$$\text{conv 4: } 256 \left(\frac{S}{8} \right)^2 = 4S^2$$

$$\text{conv 5: } 256 \left(\frac{S}{16} \right)^2 = S^2$$

$$\text{conv 6: } 512 \left(\frac{S}{16} \right)^2 = 2S^2$$

$$\text{GAP: } 512, \text{ fc 1: } 256, \text{ fc 2: } 100$$

Параметры:

$$N = 32 \cdot 3 \cdot 49 + 64 \cdot 32 \cdot 25 + 128 \cdot 64 \cdot 9 + 256 \cdot 128 + 256 \cdot 256 \cdot 9 + 512 \cdot 256 + 512 \cdot 256 + 256 + 256 \cdot 100 + 100 =$$

$$W = 4N = 4161296 \text{ байт.} \quad = 1040324$$

3. FLOPs (S, B)

$$F_{\text{conv}} = 2B C_{\text{out}} H_{\text{out}} W_{\text{out}} C_{\text{in}} K^2,$$

$$F_{\text{Lin}} = 2B \cdot \text{in} \cdot \text{out}$$

MAC на одно изображение:

$$\text{conv1: } 32 \cdot 3 \cdot 49 \cdot S^2 / 4 = 1176 S^2$$

$$\text{conv2: } 64 \cdot 32 \cdot 25 \cdot S^2 / 16 = 3200 S^2$$

$$\text{conv3: } 128 \cdot 64 \cdot 9 \cdot S^2 / 64 = 1152 S^2$$

$$\text{conv4: } 256 \cdot 128 \cdot S^2 / 64 = 512 S^2$$

$$\text{conv5: } 256 \cdot 256 \cdot 9 \cdot S^2 / 256 = 2304 S^2$$

$$\text{conv6: } 512 \cdot 256 \cdot S^2 / 256 = 512 S^2$$

$$\text{fc1+fc2: } 512 \cdot 256 + 256 \cdot 100 = 156672$$

$$\text{Сумма: } 8856 S^2 + 156672 \text{ MAC.}$$

$$\text{FLOPs (S, B)} = B (17712 S^2 + 313344)$$

4. Bytes moved (S, B)

$$\text{conv: } 4(B n_{\text{in}} + n_w + B n_{\text{out}})$$

$$\text{ReLU inplace: } 2 \cdot 4 B n \text{ (чтение + запись)}$$

$$\text{MaxPool: } 4B(n_{\text{in}} + n_{\text{out}}) + 8B n_{\text{out}}$$

$$\text{AvgPool, Linear: } 4(B n_{\text{in}} + n_w + B n_{\text{out}})$$

По формулам (F_k и Bytes_k для всего слоя):

$$\text{conv1: } F = 2352 B S^2, \text{ Bytes} = 44 B S^2 + 18816$$

$$\text{ReLU: Bytes} = 64 B S^2$$

$$\text{MaxPool: Bytes} = 56 B S^2$$

$$\text{conv2: } F = 6400 B S^2, \text{ Bytes} = 24 B S^2 + 204800$$

$$\text{ReLU: } 32 B S^2$$

$$\text{conv3: } F = 2304 B S^2, \text{ Bytes} = 24 B S^2 + 294912$$

$$\text{ReLU: } 16 B S^2$$

$$\text{conv4: } F = 1024 B S^2, \text{ Bytes} = 24 B S^2 + 131072$$

$$\text{ReLU: } 32 B S^2$$

$$\text{conv5: } F = 4608 B S^2, \text{ Bytes} = 20 B S^2 + 2359296$$

$$\text{ReLU: } 8 B S^2$$

$$\text{conv6: } F = 1024 B S^2, \text{ Bytes} = 12 B S^2 + 524288$$

$$\text{ReLU: } 16 B S^2$$

$$\text{AvgPool: Bytes} = 8 B S^2 + 2048 B$$

$$\text{fc1: } F = 262144 B, \text{ Bytes} = 3072 B + 525312$$

$$\text{ReLU: } 2048 B$$

$$\text{fc2: } F = 51200 B, \text{ Bytes} = 1424 B + 102800$$

$$\text{Bytes (S, B)} = B (380 S^2 + 8592) + 4161296$$

5. Memory (S, B)

Допущения:

- во время inference только по вход и выход, промежуточные тензоры освобождаются (Sequential + inference-mode)

- вход x первым вызывающий код без forward: $12BS^2$ байт

- ReLU inplace новой памяти не выделяет

- MaxPool на cuda выделяет индекс int64 размером с выход

- Workspace cuBLAS $W_{cuBLAS} = 9568256$ байт выделяется при первом Linear и остается.

- Workspace cuDNN не универсально: он зависит от алгоритма, который выбирает библиотека, а не от сети.

Inplace тензоры во время inference (байт на умножение, байт x и весов):

$$\text{conv1}: 4 \cdot 8 S^2 = 32 S^2$$

$$\text{MaxPool}: 4 \cdot 8 S^2 + 4 \cdot 2 S^2 + 8 \cdot 2 S^2 = 56 S^2$$

$$\text{conv2}: 4 \cdot (2+4) \cdot S^2 = 24 S^2$$

$$\text{conv3}: 4 \cdot (4+2) \cdot S^2 = 24 S^2$$

$$\text{conv4}: 4 \cdot (2+4) \cdot S^2 = 24 S^2$$

$$\text{conv5}: 4 \cdot (4+1) \cdot S^2 = 20 S^2$$

$$\text{conv6}: 4 \cdot (1+2) \cdot S^2 = 12 S^2$$

Максимум у MaxPool

$$\text{Memory}(S, B) = W + W_{cuBLAS} + (12 + 56)BS^2 = 13729552 + 68BS^2 \text{ байт}$$

6. Latency (S, B, \theta)

Допущения:

- За forward 17 кернелов (6 conv, 7 ReLU, MaxPool, AvgPool, 2 Linear), выполняются последовательно.

- Время кернела определяет самый медленный ресурс: запуск с CPU, прирост или память.

- P_k и BW эффективные, подбираются по замерам.

- При $B > 64$ cuDNN переключается conv2 на FFT, тогда для conv2 берется P_{conv2}^{FFT}

$$T(S, B, \theta) = t_0 + \sum_{k=1}^K \max(t_{\text{launch}}, \frac{F_k(S, B)}{P_k}, \frac{P_{\text{bytes}_k}(S, B)}{BW})$$

$$\theta = (t_0, t_{\text{launch}}, BW, P_{\text{conv1}}, \dots, P_{\text{conv6}}, P_{\text{fc1}}, P_{\text{fc2}}, P_{\text{conv2}}^{FFT})$$

Три типа max combinations 3-х параметров:

launch-bound: $T \rightarrow t_0 + 17t_{\text{launch}}$, не зависит от S и B

memory-bound: $T_k \approx \text{Bytes}_k / BW$ (ReLU, нулики)

compute-bound: $T_k \approx F_k / P_k$ (вертки)

4. Energy (S, B, θ)

Допущения:

- пока идет forward, GPU тратит постоянную мощность P_{static} , эта часть энергии пропорциональна времени.
- динамическая энергия пропорциональна работе: e_{flop} на FLOP и e_{byte} на байт DRAM
- время T берется из модели latency.

$$E(S, B, \theta) = P_{\text{static}} T(S, B, \theta) + e_{\text{flop}} \text{FLOPs}(S, B) + e_{\text{byte}} \text{Bytes}(S, B)$$

$$\theta_{\text{energy}} = (P_{\text{static}}, e_{\text{flop}}, e_{\text{byte}}) \text{ и } \theta \text{ из latency}$$